

Série 2

Régression Logistique

Exercice 1 : Classification binaire simple

On dispose d'un jeu de données avec deux caractéristiques x_1 et x_2 , et une variable cible $y \in \{0, 1\}$. Les données sont les suivantes :

x_1	x_2	y
2	3	1
1	5	0
3	1	1
0	2	0

Le modèle de régression logistique est donné par :

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}},$$

où $x = [1, x_1, x_2]^T$ (ajout du biais), et $\theta = [\theta_0, \theta_1, \theta_2]^T$ est le vecteur de paramètres.

1. Écrivez la fonction coût logistique pour ce problème :
2. Montrer que les gradients pour mettre à jour θ avec la méthode de descente de gradient sont:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}, \quad j = 0, 1, 2.$$

3. Implémentez une itération de descente de gradient pour un pas d'apprentissage $\alpha = 0.1$.

Exercice 2 : Évaluation d'un classificateur

Un modèle logistique a été entraîné avec les paramètres suivants :

$$\theta_0 = -3, \quad \theta_1 = 0.8, \quad \theta_2 = 1.2.$$

1) Pour chaque exemple de test (x_1, x_2) , calculez la probabilité prédite $h_{\theta}(x)$ et la prédiction binaire \hat{y} : ($\hat{y} = 1$ si $h_{\theta}(x) \geq 0.5$, sinon $\hat{y} = 0$) :

- $x = (2, 3)$,
- $x = (1, 5)$,

- $x = (0, 1)$.

2) Supposons les vrais labels pour ces exemples soient $y = [1, 0, 0]$. Calculez les métriques suivantes :

a. **Exactitude (Accuracy)** :

$$\text{Exactitude} = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'exemples}}.$$

b. **Précision (Precision), Rappel (Recall) et F1-score** pour la classe $y = 1$.

Exercice 3 : Régression logistique multiclasse (One-vs-All)

On dispose d'un jeu de données pour une classification à 3 classes : $y \in \{0, 1, 2\}$. La régression logistique doit être utilisée avec la méthode **One-vs-All**.

Entraînez trois classificateurs logistiques $h_{\theta}^{(k)}(x)$ pour chaque classe $k \in \{0, 1, 2\}$, où :

$$h_{\theta}^{(k)}(x) = P(y = k|x, \theta).$$

1. Écrivez la fonction coût pour un classificateur donné k .
2. Implémentez les mises à jour des gradients pour un seul classificateur.
3. Une fois les trois modèles entraînés, donnez la règle de prédiction pour attribuer une classe :

$$\hat{y} = \arg \max_k h_{\theta}^{(k)}(x).$$

Exemple d'application

Pour un point $x = [1, 2]^T$, et les paramètres des trois modèles :

$$\theta^{(0)} = [-1, 0.5, 0.3], \quad \theta^{(1)} = [0.2, -0.1, 0.8], \quad \theta^{(2)} = [0.7, -0.4, 0.2],$$

calculez la probabilité associée à chaque classe et donnez la classe prédite.

Exercice 4 : Application avancée de la régression logistique

Nous considérons un ensemble de données de taille $m = 4$, avec deux caractéristiques x_1 et x_2 (y compris un biais implicite ajouté $x_0 = 1$ pour toutes les observations) et leurs labels y correspondants.

Exemple	x_1	x_2	y
1	0.5	1.2	0
2	1.5	0.7	1
3	2.0	1.0	1
4	1.0	1.5	0

Appliquer la regression logistique à ce problème

Exercice 5 : Analyse multicatégorie avec régression logistique

Considérons un problème de classification avec trois classes C_1, C_2, C_3 . Vous disposez d'un jeu de données avec deux caractéristiques x_1 et x_2 , ainsi que les étiquettes correspondantes.

1. Développez un modèle de régression logistique multinomial (softmax) pour prédire la probabilité d'appartenance à chaque classe.
2. Écrivez la fonction coût multinomiale adaptée.
3. Implémentez une descente de gradient pour ajuster les paramètres.

Exercice 6 : Interaction des caractéristiques dans un modèle de régression logistique

Dans cet exercice, vous allez étudier l'impact des interactions entre les caractéristiques dans un modèle de régression logistique. Vous êtes invités à comparer deux approches : avec et sans termes d'interaction.

Données initiales

Les données suivantes sont fournies :

x_1	x_2	x_3	y
0.5	1.2	0.8	0
1.5	0.7	1.0	1
2.0	1.0	1.5	1
1.0	1.5	1.2	0

1. **Modèle avec interactions** Implémentez une régression logistique où la fonction hypothèse est donnée par :

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T \tilde{x}}},$$

avec $\tilde{x} = [1, x_1, x_2, x_3, x_1x_2, x_1x_3, x_2x_3]^T$. Suivez les étapes suivantes :

- (a) Construisez la matrice étendue \tilde{X} à partir des données initiales en incluant les termes d'interaction (x_1x_2, x_1x_3, x_2x_3) .
- (b) Entraînez le modèle à l'aide de la descente de gradient en initialisant $\theta = 0$.
- (c) Affichez les paramètres θ appris et les prédictions pour un point de test donné $x_{\text{test}} = [1.2, 0.8, 1.1]$.

Exercice 7 : Comparaison de modèles de régression logistique avec et sans interactions

On considère un problème de classification binaire avec les données suivantes :

x_1	x_2	x_3	Classe (y)
0.5	1.2	0.8	0
1.5	0.7	1.0	1
2.0	1.0	1.5	1
1.0	1.5	1.2	0

(a) **Modèle avec interactions** Implémentez une régression logistique qui inclut :

- Un biais ($x_0 = 1$),
- Les caractéristiques originales (x_1, x_2, x_3),
- Les termes d'interaction ($x_1 \cdot x_2, x_1 \cdot x_3, x_2 \cdot x_3$).

Utilisez une descente de gradient pour ajuster les paramètres du modèle (θ). Testez la prédiction pour le point $[1.2, 0.8, 1.1]$. Affichez la probabilité prédite et la classe attribuée ($y = 0$ ou $y = 1$).

(b) **Modèle sans interactions** Implémentez une régression logistique en utilisant uniquement :

- Un biais ($x_0 = 1$),
- Les caractéristiques originales (x_1, x_2, x_3).

Testez également la prédiction pour le point $[1.2, 0.8, 1.1]$. Affichez la probabilité prédite et la classe attribuée.

(c) **Comparaison des résultats**

- Comparez les paramètres appris (θ) dans les deux cas.
- Comparez les probabilités prédites et les classes attribuées pour le point testé.
- Discutez l'impact des termes d'interaction sur la performance du modèle. Dans quel cas leur inclusion peut-elle être bénéfique ?

Exercice 8 : Régularisation

Pour éviter le sur-apprentissage sur un petit ensemble de données, ajoutez une régularisation L_2 .

(a) Développez la fonction coût régularisée :

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

- Implémentez la descente de gradient modifiée pour tenir compte de la régularisation.
- Testez sur un ensemble de données où une caractéristique est beaucoup plus importante que les autres.